Fakultet Elektrotehnike i Računarstva

Projekt R

Tehnička dokumentacija

Sustav za procesiranje dokumenata pisanih pisaćom mašinom

Student
Lovro Magdić

Nastavnik
Juraj Petrović

Siječanj 15, 2023.

1 Opis razvijenog proizvoda

Cilj ovog projekta bio je razviti sustav za procesiranje dokumenata pisanih mašinom za tipkanje. Sustav korisniku omogućuje lakše vizualno pregledavanje dokumenata, te također lakše računalno iščitavanje teksta na dokumentima. Rad sustava je koncipiran na način da sve što se od korisnika očekuje da valjana putanja gdje se dokumenti nalaze, sve ostalo sustav radi sam, odabir najboljih parametra za svaku sliku pojedinačno, rotacija dokumenata ako je potrebno te stvaranje mapa sa svakim korakom obrade dokumenta.

Cijeli proces obrade se odvija se kroz naredbeni redak odnosno u razvojnom okruženju po odabiru korisnika. Za razvijanje sustava korišten je Visual Studio Code (VSCode).

Sustav je razvijen za python3 te zahtjeva razvojnu biblioteku openCV. OpenCV je biblioteka programskih funkcija za računalni vid u stvarnom vremenu, njezine funkcionalnosti koristimo za razne obrade, spremanja i čitanja dokumenata.

2 Opis rada sustava

2.1 Binary threshold i Image deskew

U navedenom koraku koristimo navedene funkcije obrade: Binary threshold i Image deskew.
Threshold je segmentacijska funckija pomoću koje postižemo crno-bijelu sliku iz "grayscale" formata ili slike u boji.Preciznije za inicjalni threshold koristimo varijantu "Binary Threshold". Kao parametre prima granicu do koje nijanse sive postaju crne i iznad navedene granice nijanse sive postaju bijele.

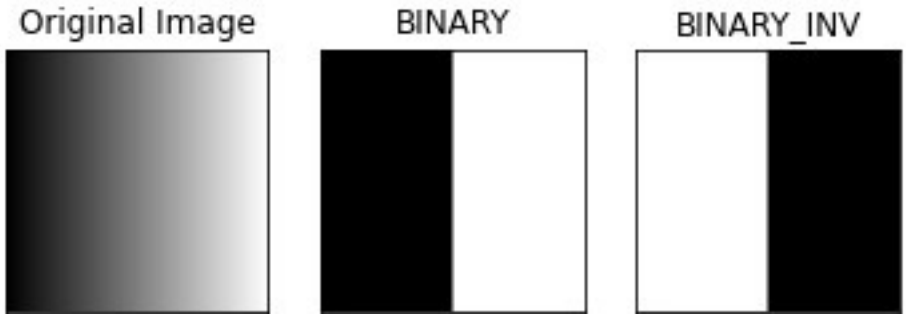

Binary threshold nam omogućuje uklanjanje raznih artefakata koji bi otežali proces "Hough Line Transform".

Hough Line Transform je jednostvani transformacijski proces pomoću kojeg pronalazimo ravne linije na slici, u našem slučaju rubove papira na slici koja je prošla threshold. Nakon detekcije linija, računamo njihovu orijentaciju s obziorm na os apscise i time dobivamo kut zakrivljenosti. Navedeni kut odnosno kutevi nam olakšavaju postizanje uspravnosti papira na slici.

Određenim kutem zakrivljenosti ostaje nam samo rotacija slike. Za to koristimo definiranu funckiju "rotateImage" koja obavlja rotaciju slike pomoću integrirane fuckije "warpAffine" iz biblioteke openCV, koja rotira sliku s obzirom na centar slike.

```
def rotateImage(cvImage, angle: float):
    newImage = cvImage.copy()
    (h, w) = newImage.shape[:2]
    center = (w // 2, h // 2)
    M = cv2.getRotationMatrix2D(center, angle, 1.0)
    newImage = cv2.warpAffine(newImage, M, (w, h), flags=cv2.INTER_CUBIC,
        borderMode=cv2.BORDER_REPLICATE)
    return newImage
```

Rotacija se ne provodi na slici koja je prošla threshold već na originalnoj slici, threshold sliku koristimo za izračun rotacije.

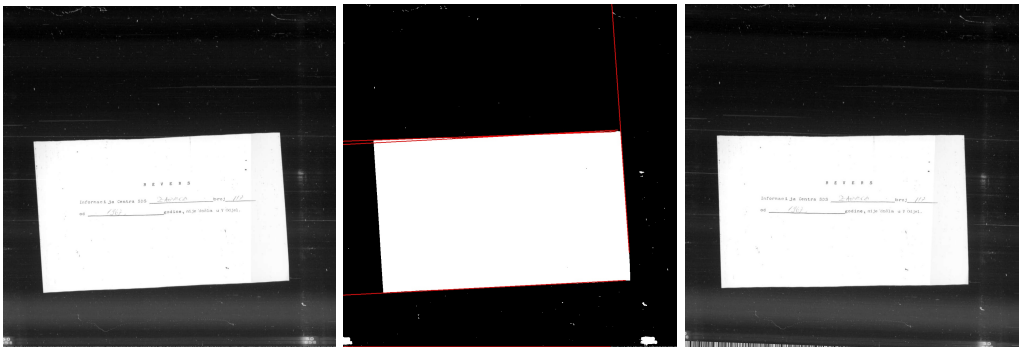

2.2 Contour detection

Sljedeći korak u procesu obrađivanja slika je "contour detection". Izuzetno je bitan za kasniju primjenu "adaptive threshold" i za izuzimanje nepotrebnih informacija iz slike (crne pozadine i artefakata). Radi na jednostavnom principu označavanja kontinuiranih točaka te lokaliziranje istih u skupinu odnosno konturu.

Detekciju kontura provodimo na threshold slici a konture primjenjujemo na originalnoj odnosno rotiranom originalu.

Kako bi postigli optimalnu konturu za svaku sliku provodimo detekciju optimalnog parametra threshold funckije za savaku sliku zasebno. Koristimo threshold u intervalu (100, 235) i računamo površinu konture koju je detektirao, određujemo razliku maksimalne konture i površine koju je sustav odredio za trenutni threshold. Optimalni threshold imat će najmanju razliku jer u tom slučaju imamo najpreciziju konturu stvarnom papiru na slici.

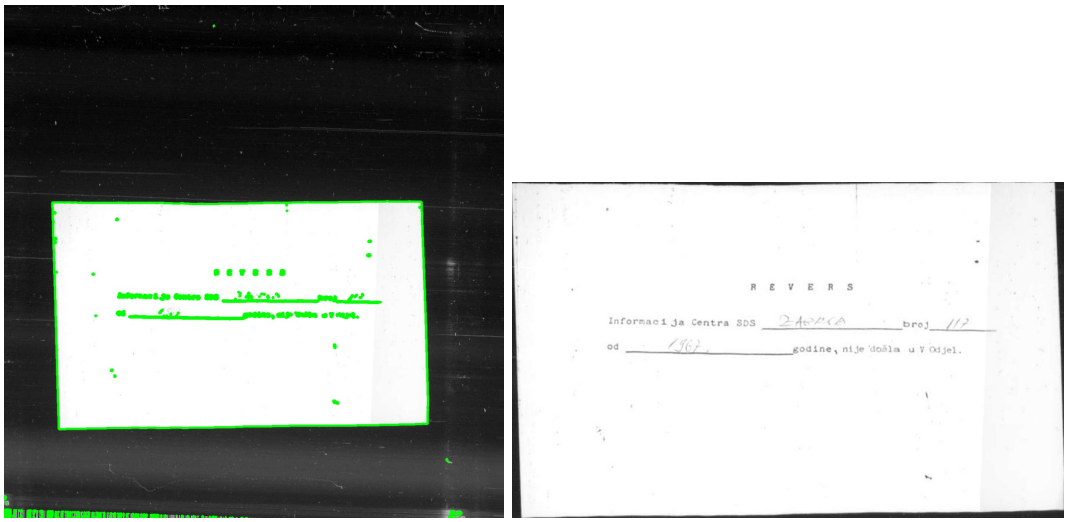

```
for i in range(100, 235, 5):
        image = cv2.imread(each)
        img_gray = cv2.cvtColor(image, cv2.COLOR_BGR2GRAY)
        ret, thresh = cv2.threshold(img_gray, i, 255, cv2.THRESH_BINARY)

        contours, hierarchy = cv2.findContours(image=thresh, mode=cv2.RETR_TREE,
            method=cv2.CHAIN_APPROX_NONE)
        image_copy = image.copy()

        cv2.drawContours(image=image_copy, contours=contours, contourIdx=-1, color=(0, 255,
            0), thickness=2, lineType=cv2.LINE_AA)

        c = max(contours, key = cv2.contourArea)
        x,y,w,h = cv2.boundingRect(c)

        ar.append([cv2.contourArea(c), w*h, i])
        array.append(int(w*h)-int(cv2.contourArea(c)))

    index = array.index(min(array))
```

2.3 Gaussian blur

Primjenom Gaussove funkcije u procesu zamućivanja slike smanjujemo detalje i šum prisutan na slici. Postignuti produkt nazivamo "Gaussian blur".

2.4 Adaptive threshold

Razina svjetlosti varira između slika čak i na jednoj slici možemo uočiti više razina svjetlosti to nam otežava određivanje optimalnog parametra thresholda.
Kako bi rješili taj problem koristimo funkciju "adaptive threshold" koja izračunava threshold parametar za piksele s obzirom na susjedne piksele. Time dobivamo različite vrijednosti thresholda za područja različitog osvjetljenja.

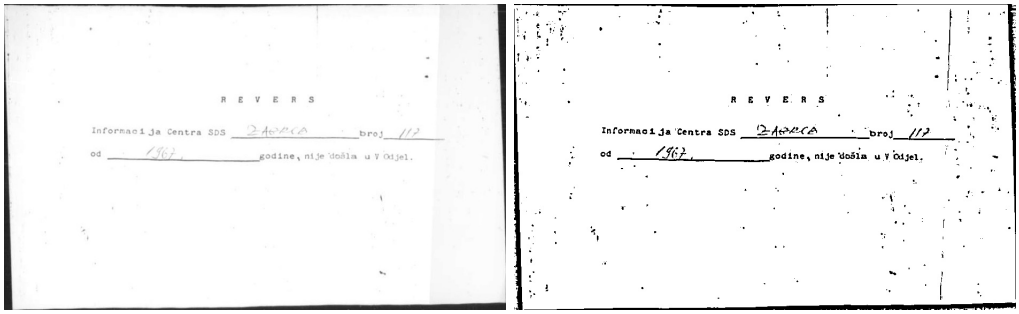

```
img = cv2.imread(each, 0)
image = cv2.adaptiveThreshold(img, 255,cv2.ADAPTIVE_THRESH_GAUSSIAN_C,
    cv2.THRESH_BINARY,25,4)
```

2.5 Font thinning

Kako bi olkšali optičko prepoznavanje znakova primjenjujemo proces stanjivanja fonta kojim također izbacujemo nepotreban šum oko znakova i postižemo detaljniju sliku.

```
def thin_font(image):
    image = cv2.bitwise_not(image)
    kernel = np.ones((2,1),np.uint8)
    image = cv2.erode(image, kernel, iterations=1)
    image = cv2.bitwise_not(image)
    return (image)
```

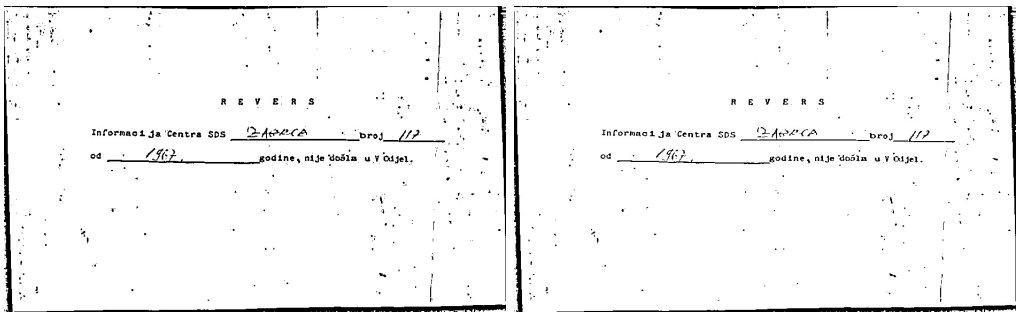

3 Upute za korištenje

Najnovija stabilna verzija dostupna je na github-u.

```
git clone git@github.com:LovroMagdic/Image-preprocessing.git
```

Sustav je razvijen za python3 te zahtjeva razvojne biblioteke openCV i Tesseract Python.

```
pip install opencv-python
pip install pytesseract
```

Nakon kloniranja repozitorija korisnik postavlja slike nad kojima želi provesti procesiranje u mapu "dataset" te pokreće "image_preprocessing.py". Sustav sam kreira preostale mape, rezultat obrade nalazi se u mapi "dataset_final" odnosno isčitani podatci u "ocr".

4 Literatura